

Predição de Sujidade em Praia por Mineração:

Engenharia Física de Features em Regime de Small Data

Relatório Técnico Completo — Pipeline ETL, EDA e Modelagem SOTA

Jorge Metri

Projeto MLOps — Predição de Deposição de Particulados

Fevereiro 2026

Sumário

1	Abstract & Resumo Executivo	3
1.1	Contexto do Problema	3
1.2	A Tese: Engenharia Física Supera Complexidade Algorítmica	3
1.3	Resultados Principais	3
1.4	Estrutura do Relatório	3
2	Auditoria de Saúde dos Dados	4
2.1	RAMPs — Meteorologia de Alta Frequência	4
2.1.1	Diagnóstico de Nulos por Sensor	4
2.1.2	Outliers Físicos	4
2.1.3	Tratamento SOTA Adotado	5
2.2	Polígonos — Emissões Industriais	5
2.2.1	Venenos Identificados	5
2.2.2	Tratamento SOTA Adotado	5
2.3	Carregamento — Processo Portuário	6
2.3.1	Veneno #1: H_2O (%) — Outliers Fisicamente Impossíveis	6
2.3.2	Veneno #2: Vírgula Decimal como String	6
2.3.3	Veneno #3: Esparsidade Operacional (Zeros Estruturais)	7
2.3.4	A Cura: Estratégia de Imputação “Carregamento Zero” (SOTA)	7
2.4	Chuva — Precipitação (Open-Meteo)	8
2.4.1	Diagnóstico	8
2.5	Target (Y) — Peso do Filtro	8
2.5.1	Distribuição do Target	9
2.6	ABT Final (Pós-ETL)	9
3	Unificação Matemática — ETL Rigoroso	10
3.1	Janela de Integração de 24 Horas	10
3.2	Integral de Riemann para Massa de Emissão	10
3.3	Decomposição Vetorial do Vento	10
3.3.1	O Erro Fatal da Média Aritmética de Ângulos	10

3.3.2	A Solução: Componentes u, v	11
3.3.3	Agregação Diária	11
3.4	Agregação do Carregamento	11
3.5	Agregação da Precipitação	12
3.6	Resumo da Compressão Dimensional	12
4	Exploratory Data Analysis (EDA)	13
4.1	Caracterização do Target e Regimes Operacionais	13
4.2	Validação das Hipóteses Físicas de Transporte	14
4.3	Diagnóstico de Redundância e Incerteza	16
4.4	Diagnóstico dos Modelos (Figuras 8–15)	17
5	Modelagem Physics-Informed	22
5.1	Fluxo Efetivo — Geometria Direcional	22
5.2	Interação Vento/Chuva — Supressão por Washout	22
5.3	Lags Temporais — Causalidade Física	23
5.4	Resumo das Features Engenheiradas	23
6	Benchmark e Discussão SOTA	24
6.1	Tabela Comparativa Completa	24
6.2	Por que o XGBoost Baseline Venceu	24
6.3	Optuna: Rendimento Decrescente do Tuning	25
6.4	Diagnóstico da Falha Neural: KAN e MLP	25
6.4.1	KAN [39 → 16 → 1]	25
6.4.2	MLP [39 → 32 → 16 → 1]	26
7	Conclusão e Viabilidade	27
7.1	Síntese dos Resultados	27
7.2	Viabilidade de Deploy	27
7.3	Limitações Conhecidas	27
7.4	Próximos Passos	28

1 Abstract & Resumo Executivo

1.1 Contexto do Problema

A operação de mineração e embarque portuário gera emissões de material particulado que se depositam em praias adjacentes. O monitoramento é realizado por filtros gravimétricos com coleta diária, produzindo uma série temporal de **PESO DO FILTRO** (em gramas) — a variável-alvo deste estudo. O desafio central reside na predição acurada dessa variável integrando dados heterogêneos de múltiplas fontes com frequências distintas (sub-horária, horária e diária) em um regime severo de **Small Data**: apenas 316 amostras válidas ao longo de um ano completo de operação (2025).

1.2 A Tese: Engenharia Física Supera Complexidade Algorítmica

Este relatório demonstra que, em regimes de Small Data com distribuição Gamma de cauda longa, a **engenharia de features fundamentada na física do transporte de partículas** é o fator dominante de performance preditiva — superando tanto a otimização exaustiva de hiperparâmetros (Optuna, 100 trials) quanto arquiteturas neurais de fronteira (KAN, MLP).

1.3 Resultados Principais

- **Compressão de dados:** 687.220 registros brutos (4 fontes, 3 frequências) → 316 linhas × 33 colunas na ABT diária.
- **Modelo campeão:** XGBoost Baseline com Pseudo-Huber Loss — MAE = 0,049.9 g (−21,3% vs. Dummy).
- **Optuna (100 trials):** MAE = 0,050.1 g — ganho marginal de +0,000.2 g, dentro do ruído estatístico.
- **KAN [39 → 16 → 1]:** MAE = 0,091.8 g (−44,8% *pior* que o Dummy). Diagnóstico: overparametrização crítica (ratio parâmetros:amostras = 30:1).
- **Feature dominante:** `fluxo_efetivo_lag1` ($r = 0,48$ com o target) — a “memória de 24h” do sistema de deposição gravitacional.

1.4 Estrutura do Relatório

A Seção 2 apresenta a auditoria completa de saúde dos dados brutos. A Seção 3 formaliza a unificação matemática do ETL. A Seção 4 percorre as 15 figuras da análise exploratória. A Seção 5 detalha a engenharia de features physics-informed. A Seção 6 apresenta o benchmark comparativo. A Seção 7 conclui com viabilidade de deploy e próximos passos.

2 Auditoria de Saúde dos Dados

A qualidade dos dados é o alicerce de qualquer pipeline de Machine Learning. Nesta seção, diagnosticamos cada uma das cinco fontes de dados brutas, identificamos os “venenos” (erros que propagam viés silenciosamente) e justificamos as decisões de tratamento adotadas.

2.1 RAMPs — Meteorologia de Alta Frequência

Tabela 1: Ficha técnica — RAMPs

Atributo	Valor
Arquivo	<code>data/raw/ramps_2025.csv</code>
Volume	531.554 registros $\times$ 13 colunas
Frequência	15 minutos
Período	2025-01-01 00:07 a 2025-12-31 23:52
Múltiplas estações	Sim (coluna <code>Origem_Arquivo</code>)

2.1.1 Diagnóstico de Nulos por Sensor

A Tabela 2 revela uma hierarquia clara de disponibilidade. Os sensores a 10,0m — considerados *padrão ouro* pela WMO para medições de vento de superfície — apresentam $\approx 73\%$ de nulos. Paradoxalmente, são os mais confiáveis quando disponíveis, pois estão na altura padronizada e livres de interferência de edificações.

Tabela 2: Diagnóstico de nulos — sensores RAMPs

Sensor	Nulos (%)	Decisão ETL
Partículas [$\mu\text{g}/\text{m}^3$] 10,0m	94,0	Descartada
VelocidadeVento [m/s] 6,0m	91,6	Fallback (secundário)
DireçãoVento [$^\circ$] 6,0m	91,6	Fallback (secundário)
Partículas [$\mu\text{g}/\text{m}^3$] 2,0m	85,8	Descartada
Partículas [$\mu\text{g}/\text{m}^3$] 6,0m	85,8	Descartada
DireçãoVento [$^\circ$] 10,0m	72,9	Padrão ouro (primário)
VelocidadeVento [m/s] 10,0m	72,7	Padrão ouro (primário)
Partículas [$\mu\text{g}/\text{m}^3$] 3,0m	23,2	Utilizável
Partículas [$\mu\text{g}/\text{m}^3$] 16,0m	23,2	Utilizada
Partículas [$\mu\text{g}/\text{m}^3$] 9,0m	17,2	Utilizada (melhor cobertura)

2.1.2 Outliers Físicos

Dois outliers merecem atenção:

- **Partículas 10,0m:** máximo = $4.416 \mu\text{g}/\text{m}^3$. O valor típico ambiente é $< 150 \mu\text{g}/\text{m}^3$. Este ponto pode indicar uma tempestade de poeira localizada ou falha de sensor. Como o sensor de 10,0m foi descartado (94% NaN), o impacto é nulo.
- **VelocidadeVento 10,0m:** máximo = $23,3 \text{ m/s}$ ($\approx 84 \text{ km/h}$). Valor plausível para região costeira tropical em eventos de frente fria. Mantido no dataset.

2.1.3 Tratamento SOTA Adotado

1. **Vento:** Sensor de 10,0m como primário. Se NaN, imputar com sensor de 6,0m (fallback hierárquico). Caso ambos sejam NaN, manter como valor ausente — o XGBoost trata nativamente via splits direcionais.
2. **Partículas:** Utilizar sensores de 9,0m e 16,0m (melhor cobertura: 82,8% e 76,8% respectivamente). Descartar 10,0m (94% NaN), 2,0m e 6,0m (85,8% NaN).
3. **Engenharia vetorial imediata:** Converter direção (graus) $\rightarrow$ radianos $\rightarrow$ componentes u, v no momento do carregamento. Proibida qualquer média aritmética de ângulos em graus (ver Seção 3.3).

2.2 Polígonos — Emissões Industriais

Tabela 3: Ficha técnica — Polígonos

Atributo	Valor
Arquivo	data/raw/poligonos_2025.csv
Volume	138.144 registros $\times$ 3 colunas
Frequência	15 minutos
Período	2025-01-01 00:07 a 2025-12-31 23:52
Origens de emissão	5 (Torre C3, Usina 3, Usina 4, Pier, Pátio)

2.2.1 Venenos Identificados

1. **Leading whitespace no nome da coluna:** A coluna de emissão aparece como `Particulas [kg/h] 0.0 m` (com espaço inicial). Um `df.columns.str.strip()` resolve, mas a falha em detectá-lo causa `KeyError` silencioso em pipelines automatizados.
2. **Inconsistência de nomes das origens:** “Usina3” (sem espaço) vs. “Usina 4” (com espaço). Sem normalização, a pivotagem gera colunas duplicadas ou mal-alinhadas.
3. **Vírgula como separador decimal:** Em algumas versões do dataset, valores numéricos aparecem como strings com vírgula (ex: “1,09”). Sem casting preventivo, a coluna permanece como `object` e operações numéricas falham silenciosamente.
4. **Cobertura real:** 138k registros de 175k esperados (79%). Lacunas de cobertura concentradas em fontes específicas.

2.2.2 Tratamento SOTA Adotado

1. `str.strip()` em todos os nomes de coluna.
2. Normalização de origens via dicionário de mapeamento.
3. Casting preventivo: `str.replace(',', '.', '')` $\rightarrow$ `pd.to_numeric()`.
4. Pivotagem: formato Long $\rightarrow$ Wide (1 coluna por origem).

5. Imputação: polígono ausente em timestamp específico = 0,0 (sem emissão calculada). NaN somente se *todos* os polígonos estiverem vazios (falha sistêmica).

2.3 Carregamento — Processo Portuário

Tabela 4: Ficha técnica — Carregamento

Atributo	Valor
Arquivo	<code>data/raw/carregamento_2025.csv</code>
Volume	8.762 registros $\times$ 11 colunas
Frequência	Horária
Período	2024-12-31 23:00 a 2026-01-01 00:00

2.3.1 Veneno #1: H₂O (%) — Outliers Fisicamente Impossíveis

Tabela 5: Estatísticas descritivas — H₂O (%)

Estatística	Valor (%)
Mínimo	0,80
Média	5,52
Máximo	275,00

Três registros apresentam H₂O > 100% — fisicamente impossível para unidade de minério. A causa provável é erro de digitação com deslocamento de vírgula decimal (2,75 $\rightarrow$ 275). O tratamento adotado é o **clamping físico**: valores > 25% $\rightarrow$ NaN. O limiar de 25% é conservador: minérios de ferro típicos apresentam umidade entre 2% e 12%; valores acima de 25% indicam anomalia instrumental ou de registro.

2.3.2 Veneno #2: Vírgula Decimal como String

Duas colunas críticas são armazenadas como `object` (texto) por conterem vírgula como separador decimal:

- **Finos -6,3mm (%)** — ex: “12,5” em vez de 12.5
- **Tempo Estoque (dias)** — ex: “3,2” em vez de 3.2

O casting `str.replace(',', ' ', '.')` $\rightarrow$ `pd.to_numeric()` é obrigatório antes de qualquer agregação.

2.3.3 Veneno #3: Esparsidade Operacional (Zeros Estruturais)

Tabela 6: Esparsidade operacional — Carregamento

Variável	Zeros / Nulos (%)
Carregamento (TMN)	54,0% (zeros — sem navio)
Descarga Pet Coke	92,8% (evento raro)
Descarga Calcário	96,5% (evento raro)
Produto	49,3% (nulos estruturais)
H ₂ O (%)	48,9% (nulos estruturais)
Finos (%)	66,4% (nulos estruturais)

Interpretação: Os nulos não são falhas de sensor — são *zeros estruturais*. Horas sem navio atracado simplesmente não geram dados de qualidade de minério (H₂O, Produto, Tempo Estoque). Tratar esses nulos com preenchimento zero criaria um viés grave: H₂O = 0 sugeriria “minério extremamente seco”, quando na realidade não há minério sendo processado.

2.3.4 A Cura: Estratégia de Imputação “Carregamento Zero” (SOTA)

A solução em três ações preserva a semântica física dos dados:

Ação 1 — Flag binária: Criar `is_loading` (= 1 se Carregamento > 0, senão 0). O modelo aprende a distinguir regimes operacionais (navio presente vs. ausente).

Ação 2 — Produto: Preencher nulos com a categoria ‘NO_OP’ (“nenhuma operação”). Preserva a natureza categórica sem injetar informação falsa.

Ação 3 — H₂O e Tempo Estoque: Preencher com **Rolling Median** (janela de 7 dias) ou Mediana Global do Mês.

Justificativa física da Rolling Median. Quando não há navio, o minério estocado no pátio *não desaparece*. Suas propriedades físicas (umidade, granulometria, tempo de estocagem) permanecem no “estado basal” da pilha. A mediana rolante de 7 dias captura esse estado sem ser sensível a outliers pontuais — ao contrário da média, que seria distorcida pelos valores extremos de H₂O = 275%. A escolha de 7 dias reflete o ciclo operacional típico de chegada de navios, garantindo que o valor imputado represente o contexto temporal correto.

2.4 Chuva — Precipitação (Open-Meteo)

Tabela 7: Ficha técnica — Chuva

Atributo	Valor
Arquivo	<code>data/raw/chuva_2025.csv</code>
Volume	8.760 registros $\times$ 3 colunas
Frequência	Horária
Período	2025-01-01 00:00 a 2025-12-31 23:00
Nulos	0 (fonte externa confiável)
Zero-inflated	75,8% das horas = 0,0 mm
Máximo	16,5 mm/h

2.4.1 Diagnóstico

Os dados de precipitação (API Open-Meteo) são a fonte mais limpa do pipeline: zero nulos, cobertura completa ($365 \times 24 = 8.760$ horas) e consistência numérica perfeita. A única anomalia é a redundância entre as colunas `precipitacao_mm` e `chuva_mm`, que são idênticas. Uma foi removida no ETL.

A distribuição **zero-inflated** (75,8% das horas sem chuva) é característica de regiões costeiras tropicais com sazonalidade marcada. O máximo de 16,5 mm/h corresponde a um evento de chuva forte, consistente com episódios convectivos da região.

2.5 Target (Y) — Peso do Filtro

Tabela 8: Ficha técnica — Target

Atributo	Valor
Arquivo	<code>data/raw/y_2025.csv</code>
Volume	365 registros $\times$ 3 colunas
Frequência	Diária
Colunas	<code>Data</code> , <code>PESO DO FILTRO</code> , <code>CLASSE DO FILTRO</code>
Nulos no target	47/365 (12,9%) — dias sem coleta
Nulos em classe	75/365 (20,5%) — validação apenas

2.5.1 Distribuição do Target

Tabela 9: Estatísticas descritivas — PESO DO FILTRO (g)

Estatística	Valor (g)
Mínimo	0,000
Q25	0,000
Mediana	0,010
Média	0,053
Q75	0,050
Máximo	1,050
Desvio Padrão	0,111

A distribuição apresenta características de uma **distribuição Gamma com cauda longa**: baseline próximo a zero ($Q_{75} = 0,050$ g), média superior à mediana (assimetria positiva) e 11 dias com peso $> 0,3$ g (3,5% — eventos extremos). Essa morfologia tem consequências diretas para a escolha da função de perda:

- **MSE (Mean Squared Error)** penalizaria excessivamente os picos, distorcendo o aprendizado em direção aos outliers.
- **MAE (Mean Absolute Error)** é a métrica natural para distribuições assimétricas, pois pondera linearmente todos os resíduos.
- **Pseudo-Huber Loss** combina robustez a outliers com diferenciabilidade — a escolha adotada neste trabalho.

2.6 ABT Final (Pós-ETL)

Tabela 10: Ficha técnica — ABT de Modelagem

Atributo	Valor
Arquivo	<code>data/processed/abt_modeling.parquet</code>
Shape	316 linhas $\times$ 33 colunas
Nulos residuais	Apenas <code>classe_filtro</code> : 29 NaN (9,2%)
Taxa de compressão	687k registros $\rightarrow$ 316 linhas diárias

A conversão segue o pipeline: 365 dias (ano) $\rightarrow$ 318 (remoção de dias sem target) $\rightarrow$ 316 (perda de 2 linhas pela criação de lags temporais). A ABT final possui **zero nulos em todas as features preditivas** — os 29 NaN residuais estão exclusivamente na coluna `classe_filtro`, utilizada apenas para validação estratificada, nunca como feature de entrada.

3 Unificação Matemática — ETL Rigoroso

O desafio central do ETL é unificar quatro fontes de dados com frequências heterogêneas (15 min, horária, diária) em uma representação diária fisicamente coerente. Esta seção formaliza a matemática de cada etapa.

3.1 Janela de Integração de 24 Horas

O filtro gravimétrico acumula partículas continuamente. A coleta ocorre diariamente entre 08:00 e 09:00, com 09:00 adotado como referência fixa. Para cada dia D com target válido, a janela de integração é:

$$W_D = [D_{-1} \text{ 09:00}, D \text{ 09:00}] \quad (1)$$

Todos os registros dentro de W_D — independentemente de sua frequência original — são agregados em uma única linha da ABT. Essa definição garante que cada observação do target corresponde *exatamente* ao acúmulo de 24 horas de processos físicos, meteorológicos e operacionais.

Implicação para os lags. A janela de D termina às 09:00 de D e a de $D - 1$ termina às 09:00 de $D - 1$. Portanto, `lag1` refere-se à janela W_{D-1} — as condições do dia anterior completo.

3.2 Integral de Riemann para Massa de Emissão

Os Polígonos reportam taxa de emissão em kg/h a cada 15 minutos. Para obter a massa total emitida na janela de 24h, aplicamos a integral de Riemann discreta:

$$M_{\text{total}} = \sum_{t \in W_D} \text{Taxa}(t) \times \Delta t \quad (2)$$

onde:

- $\text{Taxa}(t)$ = taxa de emissão de partículas [kg/h] no timestamp t ;
- $\Delta t = 0,25\text{h}$ (intervalo de 15 minutos convertido para horas);
- M_{total} = massa total emitida em kg no período de 24h.

O cálculo é realizado **separadamente** para cada uma das 5 origens de emissão:

$$M_{\text{total}} = \underbrace{M_{\text{Torre C3}}}_{\text{massa_torre_c3}} + \underbrace{M_{\text{Usina 3}}}_{\text{massa_usina3}} + \underbrace{M_{\text{Usina 4}}}_{\text{massa_usina4}} + \underbrace{M_{\text{Pier}}}_{\text{massa_pier}} + \underbrace{M_{\text{Pátio}}}_{\text{massa_patio}} \quad (3)$$

A soma gera a coluna `emissao_total_kg`, que representa a carga total de partículas injetada na atmosfera ao longo de 24 horas.

3.3 Decomposição Vetorial do Vento

3.3.1 O Erro Fatal da Média Aritmética de Ângulos

A direção do vento em graus é uma variável **circular**: 0° e 360° representam a mesma direção (Norte). A média aritmética de graus produz resultados fisicamente absurdos. Exemplo:

Média aritmética de 350° e 10° = $\frac{350 + 10}{2} = 180^\circ$ (**Sul** — errado!)

O resultado correto é 0° (Norte), pois ambas as medições estão próximas do Norte. Este erro propaga-se para todas as features derivadas (fluxo efetivo, geometria direcional) e **invalida completamente** qualquer modelo que as utilize.

3.3.2 A Solução: Componentes u, v

A decomposição vetorial converte o ângulo circular em duas grandezas escalares cuja média aritmética é válida:

$$u = -V \cdot \sin\left(\frac{\pi \cdot \theta}{180}\right) \quad (4)$$

$$v = -V \cdot \cos\left(\frac{\pi \cdot \theta}{180}\right) \quad (5)$$

onde:

- V = velocidade do vento [m/s] a 10,0m;
- θ = direção do vento [°] a 10,0m (convenção meteorológica: de onde o vento sopra);
- u = componente zonal (leste-oeste);
- v = componente meridional (norte-sul).

Convenção de sinais. O sinal negativo em ambas as equações reflete a convenção meteorológica: θ indica a direção *de onde* o vento sopra. Um vento de Norte ($\theta = 0^\circ$) tem $u = 0$ e $v = -V$ (sopra para o Sul), consistente com a orientação geográfica.

3.3.3 Agregação Diária

A agregação na janela de 24h calcula as médias aritméticas $\bar{u}$ e $\bar{v}$ — operação válida por serem grandezas escalares, não angulares. A direção média reconstituída é:

$$\bar{\theta} = \arctan2(-\bar{u}, -\bar{v}) \times \frac{180}{\pi} \quad (6)$$

Adicionalmente, a agregação produz:

- `vento_vel_mean`: média de V na janela (intensidade média do transporte eólico);
- `vento_vel_max`: máximo de V na janela (rajada — proxy de ressuspensão máxima).

3.4 Agregação do Carregamento

Para a tabela de Carregamento (frequência horária), a agregação na janela de 24h produz:

$$\begin{aligned} \text{carreg_total_tmn} &= \sum_{t \in W_D} \text{Carregamento}(t) \quad [\text{TMN}] \\ \text{is_loading} &= \mathbb{K}[\text{carreg_total_tmn} > 0] \\ \text{h2o_media} &= \overline{\text{H}_2\text{O}}_{W_D} \quad (\text{valores imputados}) \\ \text{produto_moda} &= \text{Moda}(\text{Produto}_{W_D}) \quad \text{ou 'NO_OP'} \end{aligned} \quad (7)$$

A feature `is_loading` funciona como um *switch* de regime operacional: o modelo aprende padrões distintos para dias com e sem operação de embarque.

3.5 Agregação da Precipitação

Para a tabela de Chuva (frequência horária, Open-Meteo):

$$\begin{aligned} \text{precipitacao_mm} &= \sum_{t \in W_D} P(t) \quad [\text{mm}] \\ \text{is_rainy} &= \mathbb{I}[\text{precipitacao_mm} > \tau] \end{aligned} \tag{8}$$

onde τ é um limiar de precipitação que discrimina dias operacionalmente “secos” de dias com efeito de *washout* significativo.

3.6 Resumo da Compressão Dimensional

A Tabela 11 sintetiza a redução dimensional realizada pelo ETL.

Tabela 11: Compressão dimensional — fontes brutas $\rightarrow$ ABT

Fonte	Registros	Freq.	Colunas	Contrib. ABT
RAMPs	531.554	15 min	13	u, v , vel, partículas
Polígonos	138.144	15 min	3	5 massas + total
Carregamento	8.762	Horária	11	TMN, H ₂ O, estoque, flag
Chuva	8.760	Horária	3	precip., flag chuva
Target	365	Diária	3	peso do filtro
Total bruto	687.585	—	—	316 linhas $\times$ 33 cols

A taxa de compressão é de $\approx 2.176 : 1$ em registros, preservando toda a informação física relevante através das agregações descritas nesta seção.

4 Exploratory Data Analysis (EDA)

A análise exploratória percorre 15 figuras organizadas em três eixos: (i) caracterização do target e regimes operacionais, (ii) validação das hipóteses físicas de transporte, (iii) diagnóstico de redundância e incerteza. Cada figura constitui uma *prova* ou *contraprova* de uma hipótese específica, detalhada a seguir.

4.1 Caracterização do Target e Regimes Operacionais




Figura 1: Série temporal do PESO DO FILTRO ao longo de 2025.

A Figura 1 evidencia a morfologia Gamma do target: baseline próximo a zero ($Q_{75} = 0,050$ g) com picos esporádicos superiores a 0,6 g. A assimetria positiva (média = 0,053 g, mediana = 0,010 g) e a presença de 11 eventos extremos ($> 0,3$ g, apenas 3,5% dos dias) justificam diretamente a adoção da Pseudo-Huber Loss em detrimento da MSE — que penalizaria excessivamente esses picos e distorceria o aprendizado.




Figura 2: Box plot condicional: peso do filtro por regime operacional (`is_loading = 0` vs. 1).

A Figura 2 compara a distribuição do peso do filtro entre dias com navio atracado (`is_loading = 1`) e dias sem operação de embarque (`is_loading = 0`). O teste de Mann-Whitney U confirma diferença significativa ($p < 0,05$), validando a feature binária como discriminador legítimo de regime operacional. Dias com carregamento ativo apresentam mediana superior e maior dispersão — consistente com a hipótese de que a movimentação portuária é fonte adicional de emissão.

4.2 Validação das Hipóteses Físicas de Transporte




Figura 3: Windrose ponderada pelo peso do filtro.

A Figura 3 é a prova causal mais direta do projeto: a “pétala” predominante aponta na direção empresa→praia, confirmando que o vento transporta material particulado da área de operação industrial para o ponto de coleta do filtro. Essa direcionalidade valida a geometria GPS utilizada no cálculo do `fluxo_efetivo` e demonstra que a decomposição vetorial (u, v) captura o mecanismo físico correto.




Figura 4: Detecção de anomalias via Desigualdade de Chebyshev ($k = 3$).

A Figura 4 aplica a Desigualdade de Chebyshev ($k = 3$, distribution-free) para identificar eventos extremos. Os outliers detectados ($y > \mu + 3\sigma$) coincidem com dias de ventania intensa na direção empresa→praia, confirmando que são *fisicamente explicáveis* — não erros de medição. Essa evidência justifica manter os extremos no dataset em vez de removê-los: são eventos raros mas reais que o modelo deve aprender a aproximar.




Figura 5: Cross-correlation (CCF) entre Fluxo Efetivo e Peso do Filtro, lags de 0 a 5 dias.

A Figura 5 revela o *pico de correlação em lag 1* ($r \approx 0,48$), com decaimento monotônico até lag 5. A interpretação física é inequívoca: a poeira emitida ontem deposita-se predominantemente hoje — a “memória” do sistema de transporte e deposição gravitacional é de aproximadamente 24 horas. Esse resultado fundamenta a criação de `fluxo_efetivo_lag1` como feature e explica por que ela consistentemente domina o Feature Importance de todos os modelos treinados.




Figura 6: Efeito washout: Fluxo Efetivo vs. Peso do Filtro, colorido por `is_rainy`.

A Figura 6 confirma a hipótese de *washout*: dias chuvosos com alta emissão apresentam peso do filtro **baixo**. A chuva “lava” as partículas em suspensão ou impede a ressuspensão do material depositado, agindo como regressor negativo. O teste de Mann-Whitney U entre “Alta Carga Seca” e “Alta Carga Úmida” confirma significância ($p < 0,05$). Essa evidência justifica a inclusão obrigatória de `precipitacao_mm` e `is_rainy` no feature space, bem como a feature de interação $I = F_{\text{ef}}/(P_{\text{mm}} + 1)$.

4.3 Diagnóstico de Redundância e Incerteza




Figura 7: Scree plot do PCA aplicado aos sensores de partículas (9m e 16m).

A Figura 7 demonstra que o primeiro componente principal (PC1) captura a maior parte da variância entre os sensores de partículas a diferentes alturas. A alta redundância implica que os sensores de 9m e 16m medem essencialmente o mesmo fenômeno — a “poluição ambiental global” — e que um componente principal é suficiente para representá-la. Esse diagnóstico justifica a decisão de não incluir todos os sensores como features independentes, evitando multicolinearidade no modelo.




Figura 8: Volatilidade meteorológica na janela 08–09h vs. erro de predição.

A Figura 8 revela uma fonte de **ruído irreduzível**: dias com alta volatilidade de vento e emissão na hora de coleta (08–09h) apresentam resíduos de predição sistematicamente maiores. A imprecisão de $\pm 1h$ na hora exata de troca do filtro é uma fonte de incerteza que nenhum modelo determinístico consegue eliminar. Esse diagnóstico aponta para modelos probabilísticos (e.g., Quantile Regression, Conformal Prediction) como evolução natural do pipeline.

4.4 Diagnóstico dos Modelos (Figuras 8–15)




Figura 9: XGBoost Baseline — predições vs. valores reais ao longo do tempo.

A Figura 9 mostra que o XGBoost Baseline acompanha a tendência geral do target, com dificuldade nos picos extremos ($> 0,6g$). A subestimação dos eventos extremos é esperada e desejável: a Pseudo-Huber Loss limita a influência dos resíduos extremos, priorizando a acurácia no regime dominante ($< 0,05g$).




Figura 10: Feature Importance (Gain) do XGBoost Baseline — Top 15.

A Figura 10 confirma que a **física do transporte de partículas é capturada pelo modelo**: `fluxo_efetivo_lag1` domina o ranking, seguida por features de vento (u , v), emissão e precipitação. Features de processo portuário (carregamento, H_2O) também aparecem, confirmando a relevância operacional. A hierarquia é consistente com a cadeia causal: emissão $\rightarrow$ transporte eólico $\rightarrow$ deposição $\rightarrow$ supressão por chuva.




Figura 11: Benchmark de MAE: Random Forest vs. LightGBM vs. XGBoost.

A Figura 11 compara os três modelos baseados em árvores. O XGBoost com Pseudo-Huber Loss domina consistentemente em MAE. A superioridade sobre Random Forest (+7,5 pp) e LightGBM (+3,7 pp) deve-se à robustez da Huber Loss à cauda longa da distribuição Gamma — modelos com MSE padrão são mais sensíveis aos outliers extremos.




Figura 12: KAN $[39 \rightarrow 16 \rightarrow 1]$ — previsões vs. valores reais.

A Figura 12 ilustra a falha da KAN: a rede *suaviza* os picos e *diverge* nos extremos. O comportamento é típico de overfitting simultâneo ao underfitting: a rede memoriza o “regime baixo” (75% dos dados $< 0,05$ g) e falha completamente nos eventos extremos. A confirmação visual do diagnóstico de overparametrização (ratio 30:1 parâmetros:amostras).




Figura 13: Comparação lado a lado: KAN vs. XGBoost.

A Figura 13 expõe a divergência entre os modelos. O gap entre KAN e XGBoost *crece* nos eventos extremos: enquanto o XGBoost mantém erro relativamente constante, a KAN diverge exponencialmente. Esse padrão confirma que árvores de decisão com splits discretos são fundamentalmente mais adequadas que redes neurais com B-splines suaves para este cenário de small data com distribuição Gamma zero-inflated.




Figura 14: Histórico de otimização Optuna (100 trials, TPE Sampler).

A Figura 14 mostra convergência rápida nas primeiras 20–30 trials, seguida de plateau. O melhor MAE encontrado (0,050.1 g) é virtualmente idêntico ao baseline (0,049.9 g), com diferença de apenas 0,000.2 g. Essa evidência é a prova mais contundente da tese central: **engenharia de features domina tuning de hiperparâmetros** quando o feature space já captura a física do problema.




Figura 15: XGBoost Otimizado (pós-Optuna) — previsões vs. valores reais.

A Figura 15 demonstra performance visual equivalente ao baseline. Os picos $> 0,6$ g permanecem como fronteira de melhoria — candidatos naturais a modelagem probabilística (Quantile Regression) ou detecção de regime em trabalhos futuros.




Figura 16: Feature Importance (Gain) do XGBoost Otimizado — Top 15.

A Figura 16 confirma a **consistência estrutural** entre baseline e modelo otimizado: as mesmas features dominam em ambos (vento u , fluxo de emissão, precipitação, lags temporais). A otimização de hiperparâmetros não altera a estrutura do aprendizado — apenas ajusta pesos marginalmente. A física capturada pelas features é robusta e estável.

5 Modelagem Physics-Informed

Esta seção formaliza as features de engenharia física que constituem o diferencial do pipeline. Enquanto a Seção 3 descreve a *unificação temporal* (agregação multi-frequência), esta seção detalha a *engenharia causal*: features derivadas da física do transporte atmosférico de partículas.

5.1 Fluxo Efetivo — Geometria Direcional

O Fluxo Efetivo é a feature central do pipeline. Ele pondera a emissão de cada fonte industrial pela componente do vento na direção do ponto de coleta (praia):

$$F_{\text{ef}} = \sum_{i=1}^5 E_i \cdot \cos(\theta_{\text{vento},i} - \theta_{\text{praia}}^i) \quad (9)$$

onde:

- E_i = massa total emitida [kg] pela fonte i na janela de 24h (Eq. 2);
- $\theta_{\text{vento},i}$ = direção média do vento na RAMP i [rad], calculada via $\arctan2(-\bar{u}, -\bar{v})$;
- θ_{praia}^i = ângulo geométrico fixo da fonte i até a praia [rad].

O ângulo fonte→praia é calculado via coordenadas GPS de alta precisão:

$$\theta_{\text{praia}}^i = \arctan2(\text{Lon}_{\text{praia}} - \text{Lon}_i, \text{Lat}_{\text{praia}} - \text{Lat}_i) \quad (10)$$

com coordenadas fixas do ponto de coleta: $\text{Lat}_{\text{praia}} = -20,7957$, $\text{Lon}_{\text{praia}} = -40,5816$.

Interpretação física. O fator $\cos(\theta_v - \theta_p)$ é uma projeção vetorial:

- $\cos > 0$: vento transporta partículas *da* fonte *para* a praia (contribuição positiva);
- $\cos < 0$: vento afasta partículas da praia (contribuição negativa — efeito protetor);
- $\cos \approx 0$: vento perpendicular à linha fonte-praia (contribuição nula).

5.2 Interação Vento/Chuva — Supressão por Washout

A precipitação suprime a deposição de partículas via dois mecanismos: (i) *washout* — gotas de chuva capturam partículas em suspensão, e (ii) supressão de ressuspensão — a umidade do solo impede que partículas já depositadas sejam levantadas novamente. A feature de interação normaliza o Fluxo Efetivo pelo efeito supressor:

$$I_{\text{vc}} = \frac{F_{\text{ef}}}{P_{\text{mm}} + 1} \quad (11)$$

onde P_{mm} é a precipitação acumulada na janela de 24h. A constante +1 no denominador garante estabilidade numérica e preserva a semântica: dias secos ($P = 0$) mantêm $I_{\text{vc}} = F_{\text{ef}}$; dias chuvosos reduzem I_{vc} proporcionalmente à intensidade da precipitação.

5.3 Lags Temporais — Causalidade Física

A deposição de partículas é um processo cumulativo com inércia temporal. A poeira emitida e transportada no dia $D - 1$ pode continuar sedimentando sobre o filtro no dia D . Os lags capturam essa “memória”:

$$\begin{aligned} \text{fluxo_efetivo_lag1} &= F_{\text{ef}}(D - 1) \\ \text{fluxo_efetivo_lag2} &= F_{\text{ef}}(D - 2) \\ \text{precipitacao_lag1} &= P_{\text{mm}}(D - 1) \end{aligned} \tag{12}$$

A correlação cruzada (Figura 5) confirma que o lag 1 do Fluxo Efetivo apresenta a maior correlação com o target ($r \approx 0,48$), consistente com a escala temporal de deposição gravitacional de material particulado. O lag 2 captura efeitos residuais mais fracos, e o lag de precipitação modela o washout acumulado do dia anterior.

5.4 Resumo das Features Engenheiradas

A Tabela 12 sintetiza as 4 features de engenharia física adicionadas à ABT.

Tabela 12: Features de engenharia física

Feature	Tipo	Fundamento Físico
fluxo_efetivo_lag1	Lag temporal	Projeção direcional da emissão (dia anterior) ponderada pelo cosseno do ângulo vento-praia. $r = 0,48$ com target.
fluxo_efetivo_lag2	Lag temporal	Efeito residual de deposição de 2 dias (inércia do transporte).
precipitacao_lag1	Lag temporal	Supressão por washout acumulada no dia anterior.
interacao_vento_chuva	Interação	Fluxo Efetivo normalizado pela precipitação. Captura a competição vento vs. chuva.

A criação dos lags consome 2 linhas da ABT (lag2 requer 2 dias anteriores), resultando na dimensão final: $318 \rightarrow 316$ linhas $\times$ 33 colunas.

6 Benchmark e Discussão SOTA

Esta seção apresenta o benchmark completo de 7 modelos, incluindo 3 famílias de árvores (XGBoost, LightGBM, Random Forest), 2 redes neurais (KAN, MLP) e a otimização exaustiva via Optuna (100 trials). A validação utiliza **TimeSeriesSplit** com 5 folds e gap de 1 dia para prevenir vazamento de informação dos lags temporais.

6.1 Tabela Comparativa Completa

Tabela 13: Benchmark completo — 7 modelos avaliados por MAE e RMSE

Modelo	MAE (g)	RMSE (g)	Ganho vs. Dummy	Parâmetros
Dummy (Média)	0,063.4	—	—	—
Random Forest	0,054.6	0,088.4	+13,8%	500 árvores
LightGBM (Huber)	0,052.2	0,090.3	+17,6%	—
XGBoost Baseline	0,0499	0,0887	+21,3%	500 árvores
XGBoost Optuna	0,050.1	0,089.1	+21,0%	900 árvores
MLP [39 → 32 → 16 → 1]	0,064.3	0,109.7	−1,4%	1.921
KAN [39 → 16 → 1]	0,091.8	0,156.1	−44,8%	9.578

Métrica principal. MAE (Erro Absoluto Médio) em gramas — métrica natural para distribuições assimétricas com cauda longa.

Protocolo de validação. TimeSeriesSplit com 5 folds e gap = 1 dia. O gap previne que o lag1 do fold de treino vaze para o fold de teste.

Função de perda. `reg:pseudohubererror` para os modelos XGBoost — robusta a outliers da cauda Gamma sem descartá-los.

6.2 Por que o XGBoost Baseline Venceu

O XGBoost com Pseudo-Huber Loss emergiu como campeão por quatro razões estruturais:

1. **Pseudo-Huber Loss.** Robusta a outliers ($> 1,0$ g) sem descartá-los. A distribuição Gamma do target faz com que MSE penalize excessivamente os picos, enquanto Huber Loss limita a influência dos resíduos extremos mantendo diferenciabilidade.
2. **Tratamento nativo de NaN.** XGBoost aprende a direção ótima dos splits quando encontra valores ausentes, sem necessidade de imputação explícita. Os 29 NaN residuais em `classe_filtro` são tratados automaticamente.
3. **Regularização intrínseca.** Árvores com profundidade limitada (`max_depth = 5`) e early stopping (50 rounds) evitam overfitting natural em small data (316 amostras).
4. **Splits discretos.** A natureza discreta dos splits de árvore lida naturalmente com a distribuição zero-inflated do target (75% dos valores $< 0,05$ g) e com switches binários (`is_loading`, `is_rainy`).

6.3 Optuna: Rendimento Decrescente do Tuning

O Optuna (100 trials, TPE Sampler) explorou o espaço de hiperparâmetros:

Tabela 14: Espaço de busca do Optuna

Hiperparâmetro	Range	Escala
max_depth	[3, 10]	Inteiro
learning_rate	[0,01; 0,3]	Log
n_estimators	[100, 1000]	Step = 50
subsample	[0,5; 1,0]	Linear
colsample_bytree	[0,5; 1,0]	Linear
reg_alpha	[10^{-3} , 10]	Log
reg_lambda	[10^{-3} , 10]	Log
min_child_weight	[1, 10]	Inteiro
gamma	[0,0; 1,0]	Linear

O resultado: $MAE_{Optuna} = 0,050.1\text{ g}$ vs. $MAE_{Baseline} = 0,049.9\text{ g}$ — diferença de $+0,000.2\text{ g}$, marginal e dentro do ruído estatístico (Figura 14).

Interpretação. Com 316 amostras e 33 features physics-informed, a engenharia de features já saturou a capacidade preditiva do paradigma de árvores de decisão. O tuning de hiperparâmetros opera sobre rendimentos marginais decrescentes quando o feature space captura adequadamente a física do problema. A recomendação prática é **investir em features antes de investir em tuning**.

6.4 Diagnóstico da Falha Neural: KAN e MLP

6.4.1 KAN [39 $\rightarrow$ 16 $\rightarrow$ 1]

A Kolmogorov-Arnold Network com 9.578 parâmetros (grid = 3, $k = 3$, B-splines) obteve $MAE = 0,091.8\text{ g}$ — **44,8% pior que o Dummy**. O diagnóstico identifica cinco causas:

1. **Overparametrização crítica.** Ratio parâmetros:amostras = $9.578 : 316 \approx 30:1$. O limiar recomendado para redes neurais é $> 100:1$, idealmente $> 1.000:1$.
2. **Distribuição Gamma esparsa.** 75% dos targets $< 0,05\text{ g}$, picos até $1,05\text{ g}$. Gradientes instáveis: a rede converge para a “média” e ignora extremos.
3. **NaN handling.** Redes neurais exigem imputação explícita de todos os NaN, que introduz viés. XGBoost trata NaN nativamente via splits direcionais.
4. **Suavização excessiva.** KAN aprende funções suaves (B-splines). A relação vento $\rightarrow$ sujidade contém descontinuidades (e.g., `is_loading` é um switch binário), que XGBoost captura naturalmente via splits.
5. **Treinamento com Huber Loss** ($\delta = 0,15$). O delta atenua outliers mas não resolve a instabilidade de gradientes com n tão pequeno.

6.4.2 MLP [39 → 32 → 16 → 1]

O Multilayer Perceptron com 1.921 parâmetros (BatchNorm, GELU, Dropout) obteve $MAE = 0,064.3g - 1,4\%$ *pior* que o Dummy. O ratio parâmetros:amostras de $\approx 6:1$ é superior ao da KAN, o que explica a falha menos severa, mas ainda insuficiente para generalização.

Conclusão do diagnóstico neural. Em regimes de Small Data com distribuição Gamma zero-inflated, modelos baseados em árvores de decisão são **estruturalmente superiores** a redes neurais. A superioridade não decorre de tuning — decorre de propriedades intrínsecas: tratamento nativo de NaN, splits discretos para switches operacionais e regularização implícita por profundidade limitada.

7 Conclusão e Viabilidade

7.1 Síntese dos Resultados

Este trabalho demonstrou que a predição de deposição de material particulado em praia adjacente a operações de mineração e embarque portuário é viável com acurácia operacionalmente útil, sob as seguintes condições:

1. **Compressão e unificação:** 687.220 registros brutos (4 fontes, 3 frequências) foram unificados em uma ABT diária de 316 linhas $\times$ 33 colunas, com taxa de compressão de $\approx 2.176:1$ e zero nulos em features preditivas.
2. **Engenharia física > complexidade algorítmica:** O XGBoost Baseline com 33 features physics-informed e Pseudo-Huber Loss atingiu $MAE = 0,049.9\text{ g}$ ($-21,3\%$ vs. Dummy), sem necessidade de tuning exaustivo (Optuna $MAE = 0,050.1\text{ g}$, ganho nulo).
3. **Feature dominante:** `fluxo_efetivo_lag1` ($r = 0,48$ com o target) — a projeção direcional vento-emissão do dia anterior — é o preditor mais importante em todos os modelos, consistente com a física de deposição gravitacional (memória $\approx 24\text{h}$).
4. **Redes neurais inviáveis:** KAN ($-44,8\%$) e MLP ($-1,4\%$) falharam devido a overparametrização em Small Data. O ratio parâmetros:amostras é o gargalo, não a arquitetura.

7.2 Viabilidade de Deploy

O modelo campeão (XGBoost Baseline) é **viável para deploy operacional** pelas seguintes razões:

- **Latência:** inferência $< 1\text{ ms}$ por amostra (CPU);
- **Formato:** modelo serializado em JSON (`models/xgb_baseline.json`), compatível com qualquer runtime XGBoost;
- **Dependências:** apenas `xgboost`, `pandas` e `numpy` — stack mínima;
- **Monitoramento:** Feature Importance estável entre baseline e otimizado — o modelo é robusto a re-treinamento;
- **Reprodutibilidade:** pipeline completo (ETL $\rightarrow$ Features $\rightarrow$ Treino $\rightarrow$ Avaliação) versionado com DVC e Git.

7.3 Limitações Conhecidas

1. **Eventos extremos** ($> 0,3\text{ g}$): O modelo subestima sistematicamente os picos (11 dias, $3,5\%$ do dataset). A Pseudo-Huber Loss atenua mas não elimina o viés.
2. **Incerteza na hora de coleta:** A imprecisão de $\pm 1\text{h}$ na troca do filtro (08–09h) é fonte de ruído irreduzível (Figura 8).
3. **Small Data:** 316 amostras limitam a complexidade máxima dos modelos e impedem validação por holdout robusto.
4. **Estacionariedade:** O modelo assume que a relação emissão-transporte-deposição é estacionária ao longo de 2025. Mudanças operacionais (novos equipamentos, rotas de navio) podem invalidar o modelo.

7.4 Próximos Passos

1. **Quantile Regression:** Substituir a predição pontual por intervalos de confiança (q_{10} , q_{50} , q_{90}) para capturar a incerteza inerente ao sistema.
2. **Conformal Prediction:** Calibração de intervalos com garantia de cobertura marginal, sem suposições distribucionais.
3. **Detecção de regime:** Modelo hierárquico com classificador binário (evento normal vs. extremo) seguido de regressores especializados por regime.
4. **Dados adicionais:** Incorporar imagens de satélite (MODIS AOD) e previsões meteorológicas (NWP) para ampliar o feature space sem depender de sensores locais.
5. **Monitoramento em produção:** Implementar drift detection (PSI, KS-test) nas features de entrada e no target para alertas automáticos de degradação do modelo.